

EFC3 - MLP e SVM

Rafael Gonçalves - RA: 186062

12 de Junho de 2019

Parte I - Retropropagação de erro

A rede apresentada pode ser descrita como:

$$\mathbf{y} = \sum \mathbf{W} \mathbf{F} \left(\sum \mathbf{V} \mathbf{x} \right) \quad (1)$$

em que \mathbf{y} é o vetor de saídas, \mathbf{x} é o vetor de entradas incluindo um valor unitário para facilitar o cálculo do bias, V e W são as matrizes de peso e $\mathbf{F}(\mathbf{x})$ uma matriz diagonal com os únicos elementos não nulos sendo $\mathbf{F}_{i,i}(\mathbf{x}) = f(x_i)$

Podemos definir $\mathbf{u} = \sum \mathbf{V} \mathbf{x}$ e $\mathbf{a} = \mathbf{F}(\mathbf{u})$ para facilitar os cálculos do gradiente.

A função de custo é:

$$J = \mathbf{e}^T \mathbf{e} \quad (2)$$

Com $\mathbf{e} = \mathbf{y}_{\text{target}} - \mathbf{y}$, \mathbf{y} sendo o vetor coluna que representa a saída da rede e $\mathbf{y}_{\text{target}}$ o vetor coluna com os rótulos.

Então o cálculo do gradiente se dá da seguinte forma:

$$\frac{\partial J}{\partial \mathbf{W}} = \frac{\partial J}{\partial \mathbf{e}} \frac{\partial \mathbf{e}}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}} = 2\mathbf{e}(-1)\mathbf{a} = \delta_{\mathbf{W}} \mathbf{a}$$

$$\frac{\partial J}{\partial \mathbf{V}} = \frac{\partial J}{\partial \mathbf{e}} \frac{\partial \mathbf{e}}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{a}} \frac{\partial \mathbf{a}}{\partial \mathbf{u}} \frac{\partial \mathbf{u}}{\partial \mathbf{V}} = 2\mathbf{e}(-1)\mathbf{W} \dot{\mathbf{F}}(\mathbf{u}) \mathbf{x} = \delta_{\mathbf{V}} \mathbf{x}$$

em que $\dot{\mathbf{F}}_{i,j}(\mathbf{u}) = \dot{f}(u_i)$ se $i = j$ e vale 0 caso o contrário.

Desta maneira podemos calcular:

$$\frac{\partial J}{\partial v_{21}} = -2e_1 w_{20} \dot{f}(u_1) x_2$$

em que $u_1 = v_{01} + v_{11}x_1 + v_{12}x_2$ e $e_1 = y_{target_1} - y_1$

Parte II - Classificação binária com MLPs e SVMs

Multilayer Perceptrons

Support-vector Machines